

KDD 2019 PAPER REVIEW

Time-Series Anomaly Detection Service at Microsoft


Ren et al. - 基于 SR-CNN 的時間序列異常檢測服務

問題描述：工業級監控挑戰

大型企業（如 Microsoft）需要實時監控數百萬個時間序列指標（KPI）。

關鍵需求：

- **規模巨大**：覆蓋 Page Views, Revenue 等數百萬條業務曲線。
- **即時性**：必須在異常發生的第一時間觸發警報。
- **準確性**：誤報（False Positive）會導致運維人員疲勞，漏報（False Negative）則可能造成巨大商業損失。



傳統 SPC 方法的侷限性

統計過程控制 (SPC)

傳統方法如 3-Sigma、Holt-Winters 或簡單的閾值設定。

運作方式： 依賴歷史數據的統計特性（均值、標準差）來定義正常範圍。

面臨的崩潰點

- **無法處理週期性：** 對於具有強烈季節性或週期波動的數據，固定閾值會產生大量誤報。
- **分佈漂移：** 業務數據分佈隨時間變化，需要頻繁的人工調整參數。
- **冷啟動問題：** 新上線的業務缺乏足夠的歷史數據進行統計建模。

核心挑戰與解決思路



挑戰 1：缺乏標註

問題：數據量太大，無法人工標註所有異常。

解決思路：

採用無監督學習方法，並結合合成數據生成技術。

挑戰 2：泛化能力

問題：曲線模式多樣（週期、穩定、不穩定），單一模型難以適應。

解決思路：

引入計算機視覺中的**Spectral Residual (SR)** 算法，提取通用顯著性特徵。



挑戰 3：效率要求

問題：需在線上即時處理百萬級數據流。

解決思路：

基於 FFT 的矩陣運算極快，結合輕量級 CNN 進行判別。

核心思路：從視覺顯著性到異常檢測

論文創新地借鑒了計算機視覺領域的顯著性檢測 (Saliency Detection) 概念。

基本假設：

- 在圖像中，顯著性區域 (Saliency) 是吸引人眼球的部
- 在時間序列中，異常點 (Anomaly) 等同於視覺上的顯著區域。
- 通過 Spectral Residual (SR) 算法，可以在頻域中去除重複的背景信息（週期性/趨勢），僅保留顯著的「創新」部分（異常）。



訓練過程與數據構造

1. 資料形狀 (Data Shape)

模型輸入為滑動窗口 (Sliding Window) 截取的序列。


- 窗口大小 w ：例如 64 或 128。
- 預處理：為了減少邊緣效應，在序列末尾填充估計點 (Estimated Points)。
- 輸入特徵：原始序列經過 SR 變換後生成的顯著性圖 (Saliency Map)。

2. 訓練過程 (Training Process)

由於缺乏真實標籤，採用**合成異常注入**進行監督訓練。

- 隨機選擇序列中的點替換為異常值。
- 注入公式： $x = (\bar{x} + \text{mean})(1 + \text{var}) \cdot r + x$
- 這使得模型能夠學習區分 SR 輸出的「真顯著性」與噪聲。

模型架構 (SR-CNN)



架構細節

模型由兩個主要部分組成：

1. **Spectral Residual (SR) 層**：透過 FFT 和 IFFT 計算 Log Amplitude Spectrum，生成 Saliency Map。此步驟無參數，純數學變換。
2. **CNN 判別器**：
 - **卷積層**：2 層 1-D Convolution (Kernel size = window size)，提取局部特徵。
 - **全連接層**：2 層 Fully Connected Layers，將特徵映射到異常概率。
 - **輸出層**：Sigmoid 函數，輸出 $[0, 1]$ 的異常概率。

損失函數 (Loss Function)

Cross Entropy Loss


由於這是一個二元分類問題（異常 vs 正常），模型採用標準的交叉熵損失函數：

$$L = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)$$

其中 y_i 是合成數據生成的標籤（0 或 1）， p_i 是 CNN 輸出的預測概率。

優勢： 配合合成數據，使得模型能夠在無人工標註的情況下進行有監督訓練，大幅提升了對顯著性圖的判別能力。

實驗效果：性能對比



數據來源：KPI Dataset (AIOps Challenge)。SR-CNN 在 F1-Score 上顯著優於傳統 SR 方法及其他 SOTA 無監督模型。

泛化能力 (Yahoo Dataset)

數據類型 (Pattern)	SR-CNN (F1)	SR (F1)	Spot (Baseline)
Seasonal (週期性)	0.716	0.558	0.199
Stable (穩定型)	0.752	0.601	0.879
Unstable (不穩定型)	0.464	0.556	0.356
Overall (整體)	0.652	0.563	0.338

分析： SR-CNN 在各種類型的數據上表現更加均衡。相比於在特定類型（如 Stable）表現良好但在其他類型失效的 Baseline，SR-CNN 展現了極強的工業級泛化能力。


總結 (Conclusion)

Microsoft 提出的 SR-CNN 架構成功解決了工業界大規模時序異常檢測的三大難題。通過結合**視覺顯著性 (SR)** 的通用特徵提取能力與 **CNN** 的判別能力，並利用**合成數據**解決標註缺失問題，實現了高效、準確且通用的異常檢測服務。

Q & A

感謝聆聽

Image Sources



https://openobserve.ai/assets/medium_anomaly_detection_dc8932e31c_b225929220.png

Source: openobserve.ai



https://www.mdpi.com/applsci/applsci-14-11075/article_deploy/html/images/applsci-14-11075-g001-550.jpg

Source: www.mdpi.com



https://www.mdpi.com/futureinternet/futureinternet-16-00014/article_deploy/html/images/futureinternet-16-00014-g001.png

Source: www.mdpi.com